

# Evaluación de Eficiencia y Factores Clave en el Transporte de Mineral: Análisis de Desempeño de Palas y Camiones

Nombre: Milenka Zuvic

Fecha: 15/11/2024

Santiago de Chile

## Índice

Resumen.....	3
1. Introducción .....	3
2. Objetivos .....	3
3. Metodología.....	3
4. Resultados .....	4
4.1. Análisis exploratorio de datos .....	4
4.2. Ranking de Desempeño .....	8
4.3. Identificación de factores críticos .....	10
5. Conclusiones.....	12
6. Recomendaciones .....	14

## Índice de Figuras

Figura 1. Distribución de distancias recorridas en vacío y con carga.....	5
Figura 2. Matriz de correlación .....	6
Figura 3. Serie de tiempo: Cantidad de registros por día .....	7
Figura 4. Serie de Tiempo: Tendencia del tonelaje promedio diario .....	7
Figura 5. Boxplot del Ciclo total de la pala por tipo de pala.....	8
Figura 6. Ranking de eficiencia promedio de maquinaria .....	9
Figura 7. Ranking de eficiencia de desempeño en base al transporte de carga .....	10
Figura 8. Variables que más influyen en el rendimiento de equipos .....	11
Figura 9. Variables que más influyen en el rendimiento de los equipos (sin las variables “truck” y “loader”).....	12

## Índice de Tablas

Tabla 1. Variables principales .....	4
Tabla 2. Métricas del modelo .....	10
Tabla 3. Métricas de desempeño .....	11

# Resumen

De la base de datos disponible consideradas las labores de carga y transporte de diferentes palas y camiones, se examinó la eficiencia de 47 camiones CAEX y 4 palas a través de una serie de métricas claves como la cantidad transportada, los ciclos de operación y las distancias recorridas. Con ello, se llevó a cabo un exhaustivo proceso de exploratorio de datos para eliminar valores atípicos y corregir registros. Posteriormente se utilizaron técnicas de análisis estadístico y visualización para comprender las distribuciones de las variables “truck”, “loader”, “ton”, “truck\_total\_cycle”, “loader\_total\_cycle”, “n\_shovel”, “distance\_empty”, “distance\_full” y “date”. Para el proceso de detección de anomalías se identificaron 14,673 datos atípicos mediante el uso de los modelos Isolation Forest y DBSCAN. Sin embargo, no todos estos datos fueron eliminados debido a la cantidad detectada y la falta de información adicional. Por otro lado, los camiones CAEX60 y CAEX23 presentan valores de tonelaje igual a 0, lo cual indicó posibles errores de registro o datos faltantes, siendo eliminados de la base de datos. Así mismo, se realizó una clasificación del rendimiento basada en métricas normalizadas de eficiencia en carga y transporte, identificando que los CAEX con mejor desempeño de eficiencia promedio son CAEX56 y CAEX46, por otro lado, el de eficiencia promedio en base al transporte de carga son los CAEX34 y CAEX62.

Posteriormente, se empleó un modelo de aprendizaje (Random Forest) para determinar los principales factores que impactan en el desempeño de los equipos. Donde, los resultados señalaron que el tiempo total de la pala, la carga transportada y las distancias recorridas son elementos críticos que inciden en el rendimiento operativo.

## 1. Introducción

En el contexto de la actividad minera, la eficacia en la utilización de los medios de carga y transporte constituye un pilar fundamental para asegurar la eficiencia de las actividades de extracción y asegurar su rentabilidad. Para llevar a cabo este estudio, se cuenta con una base de datos que registra la operación diaria de 47 camiones CAEX y 4 palas. En la base de datos se registra tonelaje movido durante un día de operación, el ciclo total del CAEX, ciclo total de la pala, el número de paladas que son necesarias para cargar el CAEX, la distancia que recorre el CAEX vacío y lleno.

## 2. Objetivos

Identificar los equipos de mejor rendimiento en base a su eficiencia en el transporte de tonelaje

Identificar los factores críticos, determinando cuales son las variables que más influyen en el rendimiento de los equipos

## 3. Metodología

- Limpieza de la base de datos, identificación de valores nulos y datos atípicos.

- Realización de estadística descriptiva, para observar la distribución de los datos
- Visualización de gráficos, histogramas, boxplot y gráficos de dispersión.
- Implementación de un algoritmo de detección de anomalías (Isolation Forest y DBSCAN).
- Realización de cálculos de parámetros como Eficiencia de carga, utilización de capacidad, productividad de transporte, eficiencia de carga para obtener la eficiencia promedio de maquinaria.
- Cálculo de la eficiencia de carga en base al transporte de tonelaje.
- Realización del modelo de Machine Learning (Random Forest Regressor) para determinar cuales son las variables que influyen en el rendimiento de los equipos.

## 4. Resultados

### 4.1. Análisis exploratorio de datos

Se realizó el análisis exploratorio de datos al conjunto de variables:

Tabla 1. Variables principales

truck	loader	ton	n_shovel	truck_total_cycle	loader_total_cycle	distance_empty	distance_full	date
-------	--------	-----	----------	-------------------	--------------------	----------------	---------------	------

En la base de datos tenemos presente 47 camiones CAEX, 4 palas. No se observan valores nulos en las variables “truck” y “loader”.

Así mismo, se identifica que la variable ton, tiene una desviación estándar que indica cierta variabilidad en la carga del camión. El mínimo indica que hay registros con tonelaje 0, pudiendo indicar valores faltantes o errores en el registro. Por otro lado, los cuartiles muestran una posible distribución concentrada en torno a la media. Es así como, observamos que solo existen dos valores donde la variable tonelaje es 0, en los camiones CAEX60 y CAEX23, los camiones muestran haber realizado un recorrido, y se observa que los camiones fueron cargados con la misma pala, en la cual se registra que tuvo un número de paladas y un ciclo total de recorrido de transporte de carga.

Por otra parte, en el número de paladas “n\_shovel”, la desviación estándar indica una baja variabilidad de los datos y el promedio de las paladas es igual a 3. Así mismo, los mínimos y máximos nos estarían indicando una distribución asimétrica positiva sesgada hacia valores bajos menores a 4. Por lo que, el tamaño de la pala y la capacidad del CAEX estarían relacionados. Si observamos la estadística y el gráfico, vemos que la mayoría de los camiones necesitan entre 3 y 4 paladas para ser cargados. También, se observan valores altos en las estadísticas, que llegan al máximo de 15 paladas. Estos valores podrían representar casos atípicos, donde no fue óptimo el proceso de carga de materiales, como podría deberse en un cambio de material como densidad o mineralización al momento de la carga, o simplemente corresponden estadísticamente a valores atípicos, siendo un total de 2 camiones que registran

estas mediciones. Dada las diferentes posibilidades, no se eliminaron estos datos porque hace falta más información para concluir si realmente corresponden a datos atípicos.

En la variable “truck\_total\_cycle”, se observa que existe una alta variabilidad en el tiempo que toma en realizar el ciclo total del CAEX. Los mínimos y máximos reflejan variaciones operativas y posibles tiempos de espera o interrupciones de los ciclos.

El ciclo total de la pala, representado por la variable "loader\_total\_cycle," muestra un valor mínimo de 0. Al igual que en la variable de tonelaje, esto sugiere que el dato podría no haber sido registrado correctamente durante la medición o que podría corresponder a un valor nulo. Así mismo, de las estadísticas se observan 22 registros con valores 0. Acorde a lo observado, y habiendo un ciclo total de pala igual a 0, los CAEX si tuvieron cargamento y realizaron su ciclo normal. Además, se observa que, si bien no hubo ciclo de la pala, esta si trabajo con un promedio de 3 paladas en la mayoría de los cargamentos. Es importante destacar que todas las cargas fueron realizadas con palas distintas, es decir, no se repitió con la misma pala como sucedió con los valores 0 de las toneladas. También se destaca que todos los registros fueron realizados en días diferentes.

Las variables de distancia “distance\_empty” y “distance\_full”, que recorre el CAEX vacío y lleno, tienen una variabilidad significativa, probablemente debido a las rutas de transporte que siguen durante su ciclo de llenado y descarga de material. La distribución de las distancias recorridas en vacío y con carga muestran patrones similares, con picos en los mismos intervalos (Figura 1). Se observan dos puntos altos principales en la distancia vacía y con carga, aproximadamente entre los 3,000 – 4,000 metros y 7,000 – 8,000 metros, esto puede indicar rutas comunes. Aun que se observa que la distancia vacía y con carga tienen distribuciones similares, existen algunas diferencias en la frecuencia de los valores. La distancia vacía presenta frecuencias más altas que la distancia con carga. Esto podría ser que los camiones puedan tener rutas de retorno un poco diferentes o cambios, esto podría ser concordantes, ya que por lo general en minería tienden a estar cambiando los flancos de explotación y con ello los lugares de acceso y salida. En ambos casos, existen unos pocos valores que alcanzan distancias superiores que alcanzan hasta aproximadamente 15000 metros, estas distancias son poco frecuentes, podría sugerir alguna ruta atípica dentro de la operación.




Figura 1. Distribución de distancias recorridas en vacío y con carga

Así mismo, en la gráfica de histograma al eliminar los registros con valor 0 de los dos CAEX antes mencionados dentro de la variable ton, presenta una distribución del tipo normal concentrándose en los valores 300 y 350 aproximadamente.

En la matriz de correlación (Figura 2), podemos visualizar de manera más clara la correlación entre las variables. Pudiendo se observa una correlación positiva fuerte entre el ciclo total del camión y la distancia recorrida de carga (0.74), ya que un mayor recorrido del CAEX cargado implica un mayor tiempo de ciclo. La correlación positiva entre el ciclo total del camión y la distancia recorrida en vacío también destaca, pero en menor medida que la anterior (0.59). Por lo que el ciclo total del camión también aumenta con la distancia recorrida en vacío. La correlación entre la distancia vacía y distancia con carga es positiva y significativa (0.6). Indicando que la rutas que recorren los camiones vacíos y las distancias que recorren los camiones cargados tienen una relación consistente, ya que posiblemente recorran rutas similares, lo que suele suceder en algunas operaciones mineras. Existe una correlación baja entre el tonelaje y el número de paladas (0.17), lo que podría indicar que existe una ligera tendencia en aumentar el número de paladas con el tonelaje, pero con lo que hemos visualizado anteriormente no es tan del todo cierto. La baja correlación que presenta el tonelaje con varias variables sugiere que no está muy relacionado con el tiempo total de ciclo (camión y pala), y la distancia recorrida y el número de paladas. Por lo que podría indicarnos que el tonelaje puede estar determinado por otros factores fuera de las variables que se encuentran presentes.




Figura 2. Matriz de correlación

De la serie de tiempo (Figura 3), se puede observar que entre el año 2023 al 2024 existe una tendencia en alza de la cantidad de registros por día, sugiriendo un aumento en la actividad del registro o en la operación. Este aumento también podría estar relacionado a un incremento en la flota de camiones, o una mejora en la captura de datos. Existe una variabilidad considerable en el número de registros diarios. Esto podría deberse a que existen días con operaciones más intensas y otros con una baja actividad, debido a cambios de turnos, problemas climáticos, defectos en algunos equipos y/o mantenciones de equipo. También hay la posibilidad de que

estas variabilidades en los puntos máximos y bajos estén relacionados con algún periodo específico del año.




Figura 3. Serie de tiempo: Cantidad de registros por día

También de la serie de tiempo de la variable “ton” (Figura 4), es posible visualizar que en general el tonelaje promedio diario se mantiene estable entre las 315 y 320 toneladas. Existen puntos críticos considerablemente altos donde el tonelaje aumenta. Esto podría ser por uso más eficiente de los recursos. Es destacable que existen días donde hay puntos donde el tonelaje cae bajo las 310 toneladas, llegando cercano a las 300. Esto podría deberse a interrupciones, equipos defectuosos, factores climáticos, u otro tipo de situación que detenga la operación o la ralentice.

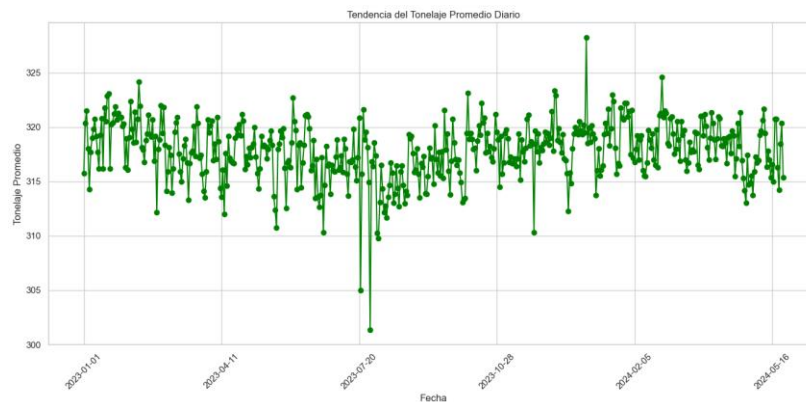


Figura 4. Serie de Tiempo: Tendencia del tonelaje promedio diario

De los boxplot (Figura 5), se observan que los cuatro tipos de palas muestran distribuciones similares en el ciclo total de la pala, esto sugiere que el tiempo de ciclo de pala no varía de manera significativa, lo cual podría sugerir que los tiempos de operación son consistentes independientemente del tipo de pala. También, se observa en cada pala valores atípicos que se encuentran sobre el rango principal, pudiendo llegar hasta valores como 12,000 segundos. Estos valores nos muestran ciclos totales de pala sobre el promedio, esto podría indicarnos algún equipo defectuoso, un tiempo de espera, una interrupción de la operación o un registro erróneo de los datos.

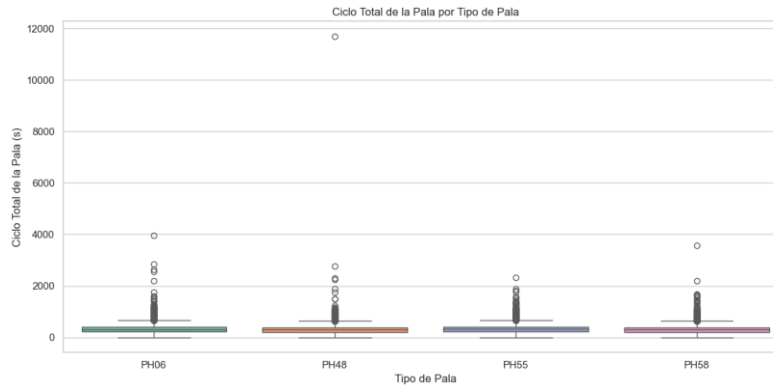


Figura 5. Boxplot del Ciclo total de la pala por tipo de pala

Por otro lado, observamos que la pala PH48 el día 10 de junio del 2023 excede su tiempo de ciclo sobre el promedio y el 75 % de la estadística de los datos. La pala se encontró casi 3 horas y media parada, o intentando realizar el proceso de carga, Esto podría indicar que la pala haya sufrido un desperfecto mecánico, ya que por lo general en minería se busca tener el menor tiempo posible de producción. Dado que en los boxplots se identifican posibles valores atípicos, se aplicaron dos técnicas de detección de anomalías: Isolation Forest y DBSCAN. La razón de emplear ambos métodos es que, sin contar con la interpretación de un experto en minería ni información adicional sobre los datos, queremos aumentar la precisión en la identificación de verdaderas anomalías. Al combinar los resultados de ambos modelos, podemos tener mayor confianza en los valores detectados, ya que una coincidencia entre los dos indica con mayor probabilidad la presencia de una anomalía real en el contexto operativo.

Finalmente, se detectaron 14,673 datos anómalos en conjunto con el Isolation Forest y DBSCAN, si bien no se eliminaron estos datos debido a la gran cantidad detectada y además debido a la falta información extra para observar si son realmente atípicos o son excepciones. A su vez, se pudo observar que los valores 0 de la variable “loader\_total\_cycle” fueron detectados en su totalidad como datos anómalos por el Isolation Forest. Ahora bien, en vez de eliminarlos se realizó una data nueva sin los datos para observar cómo se comportaban las estadísticas del modelo predictivo con los datos atípicos y sin ellos.

## 4.2. Ranking de Desempeño

Para el ranking de desempeño se realizaron algunos cálculos:

- Para la eficiencia se consideró la carga de los equipos en términos de toneladas movidas por ciclo de camión, lo cual permite entender cuántas toneladas se mueven, en promedio, por cada ciclo operativo del camión.
- Posteriormente, se calcula el porcentaje de utilización de la capacidad máxima de carga del camión. Para esto, se divide el tonelaje movido (ton) por la capacidad máxima (capacidad\_maxima), donde la capacidad máxima se asumió con el valor máximo del análisis estadístico con un valor de 384.927167. Con esto es posible obtener la capacidad total de carga, donde un valor cercano al 100% indicaría que el camión está



operando cerca de su capacidad máxima, mientras que valores menores indicarían que el camión no está aprovechando toda su capacidad.

- Luego, se determina la productividad del transporte en términos de toneladas movidas por unidad de distancia total recorrida (incluyendo tanto la distancia recorrida en vacío como cargada). Los valores altos indican una mayor eficiencia del transporte, mientras que valores bajos podrían sugerir ineficiencias como distancias innecesarias en vacío o una baja carga en cada viaje.
- Así mismo, se determino la eficiencia de carga de las palas en términos de toneladas movidas por casa ciclo de carga (palada). Un valor más alto indica que la pala está moviendo una mayor cantidad de material por cada ciclo de carga, lo cual sugiere una mayor eficiencia operativa, mientras que valores bajos indican baja eficiencia de carga.
- Luego, se determinó el tiempo de ciclo total sumando el tiempo total del ciclo del camión “truck\_total\_cycle” y el tiempo total del ciclo de la pala “loader\_total\_cycle”. Dando como resultado la variable, tiempo\_ciclo\_total, la cual representa el tiempo que toma completar un ciclo completo de carga y transporte, desde que la pala comienza a cargar hasta que el camión finaliza su recorrido y vuelve a estar listo para otra carga, pudiendo obtener la eficiencia operativa del proceso completo de carga y transporte.
- Finalmente, para calcular el ranking de desempeño de los equipos (Figura 6), se normalizaron por su valor máximo las métricas de rendimiento (eficiencia de carga, utilización de capacidad, productividad de transporte, y eficiencia de carga de la pala), ajustando todas las métricas a un rango de 0 a 1, facilitando su comparación sin que una métrica tenga mayor ponderación con un valor numérico más alto. Luego las métricas normalizadas se suman para obtener un puntaje total para cada equipo. Permitiendo evaluar el desempeño general de cada equipo.

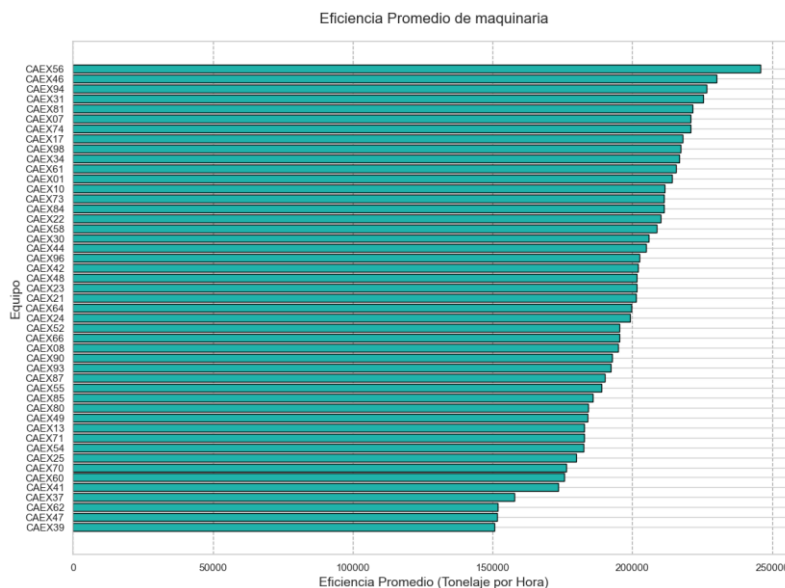


Figura 6. Ranking de eficiencia promedio de maquinaria

Por último, se realizó el mismo procedimiento para obtener un ranking de la métrica de eficiencia de carga por CAEX (Figura 7).

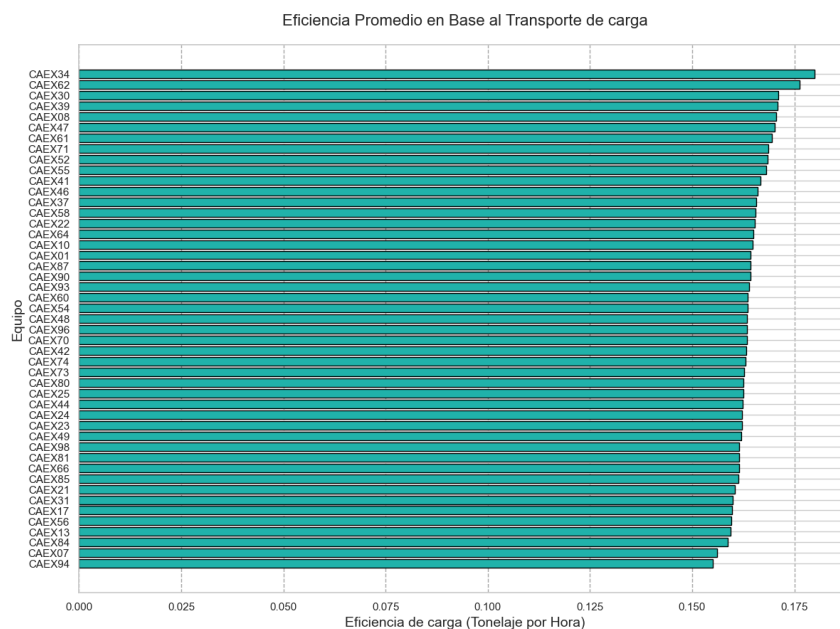


Figura 7. Ranking de eficiencia de desempeño en base al transporte de carga

### 4.3. Identificación de factores críticos

Para la identificación de los factores críticos utilizaremos el modelo random forest, esto es debido a que este modelo puede manejar un gran número de columnas, es flexible, proporciona una alta precisión, maneja bien las características de los datos, es robusto contra el sobreajuste y nos da la posibilidad de interpretar la importancia de las características de las variables.

El primer modelo se entrenó con todas las columnas, con la idea de determinar cuales variables son las mas influyentes en el rendimiento de los equipos. Tomando como variable target la eficiencia de carga. Obteniendo como resultado las métricas de la tabla 2.

Tabla 2. Métricas del modelo

Mean Squared Error (MSE)	0.0018
R2 Score	0.857

Como se observó, el valor del error promedio (MSE) es bajo, sugiriendo que las predicciones del modelo son cercanas a los valores reales. Por otro lado, el R2, presenta un valor alto, por lo que el modelo es capaz de explicar un 85.7% de la varianza de los datos.

Con ello se obtiene las 10 variables más importantes que influyen en el rendimiento de los equipos (Figura 8).




Figura 8. Variables que más influyen en el rendimiento de equipos

La variable “loader\_total\_cycle” es la variable más importante, por lo que nos estaría indicando que el tiempo de ciclo de la pala tiene una influencia crítica en el rendimiento del equipo, por lo que, el rendimiento estaría fuertemente afectado por el tiempo que toma cada ciclo total de la pala. Luego, la segunda variable más importante es “ton”, donde un tonelaje adecuado optimizar el uso del equipo, mientras que si se sobrecarga un equipo la eficiencia del transporte se puede ver afectada. Por otro lado, la distancia recorrida es la tercera variable más importante, cuanto mayor es el tiempo del transporte, se reduce el rendimiento general. Luego, la variable distancia recorrida del camión vacío “distance\_empty”, es la cuarta variable en importancia, si bien, es menos importante que las demás variables, nos refleja que influye en el rendimiento de los equipos, aunque de menor manera. El “n\_shovel”, esta variable es la quinta variable en rango de importancia, la cual podría indicarnos que un mayor número de paladas para completar un proceso de carga más lento, lo cual podría afectar la eficiencia del equipo. Finalmente, las variables restantes tienen una importancia mucho menor en el modelo, lo que indica que su impacto de rendimiento del equipo es limitado.

Posteriormente se realizó nuevamente el modelo sin considerar las variables “truck” y “loader”, para visualizar el rendimiento del modelo sin las variables categóricas (Figura 9).

Para el segundo modelo se consideró la misma variable target del modelo anterior, obteniendo los resultados de las métricas de rendimiento del modelo (tabla 3):

Tabla 3. Métricas de desempeño

Mean Squared Error (MSE)	0.001075
R2 Score	0.9162

Podemos observar que el MSE ha disminuido en comparación con el resultado anterior, lo que nos indica que el modelo es ahora más preciso. Sugiriendo que el modelo está haciendo un mejor trabajo al ajustarse sin las variables “truck” y “loader”. Por otro lado, al visualizar el R2, observamos que este aumento, obteniendo una mejora significativa en el modelo predictivo, ahora el modelo es capaz de explicar el 91.6% de variabilidad en los datos.

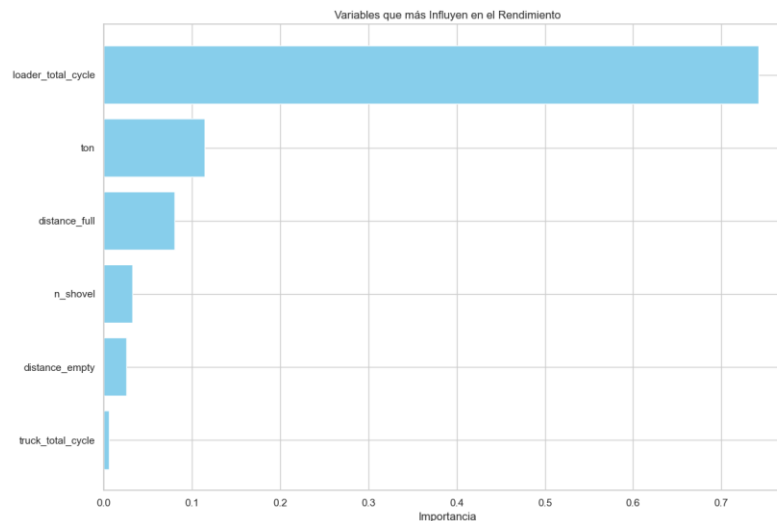


Figura 9. Variables que más influyen en el rendimiento de los equipos (sin las variables “truck” y “loader”).

En comparación con el grafico anterior se sigue manteniendo la misma predominancia en las variables “loader\_total\_cyle”, “ton”, “distance\_full”. Sin embargo, la variable “n\_shovel” paso a cuarto lugar y la distancia recorrida vacía paso a quinto, esto puede deberse a que al no contemplar las variables “truck” y “loader” se haya realizado una reducción de ruido al modelo.

## 5. Conclusiones

Del análisis exploratorio de datos se identificó que las toneladas presentan una distribución normal fluctuando en un rango de 300 y 330 toneladas, con algunos valores atípicos más bajos, que podrían deberse a problemas operativos o errores de registro. Así también, se determinó que el número de paladas necesarias para cargar un camión es de 3 a 6 aproximadamente, indicando un proceso eficiente en la mayoría de los casos, aunque paladas superiores a 7 presentan mayor variabilidad y menor eficiencia.

Del ciclo total de los camiones se presenta valores altos en torno a los 2,000 segundos y entre 3000 - 4000 segundos. Esto sugiere una relación con diferencias en rutas y condiciones de carga. Así mismo, el ciclo total de las palas es consistente entre los diferentes tipos de equipos, con valores generalmente bajos, aunque se identificaron algunos registros extremadamente largos entorno a las 3 horas, que podrían estar asociados a interrupciones o problemas técnicos.

Así también, las distancias recorridas en vacío y con carga tienen patrones similares, con valores entre 3,000-4,000 metros y 7,000-8,000 metros, indicando rutas estandarizadas. Sin embargo, las distancias mayores a 12,000 metros podrían representar casos excepcionales que impactan negativamente en la eficiencia.

Para la matriz de correlación se presenta una correlación moderada entre el ciclo total del camión y las distancias recorridas (vacío y con carga), lo que indica que las rutas tienen un impacto significativo en los tiempos de ciclo. Por otro lado, el tonelaje tiene una correlación débil con las demás variables, lo que sugiere que está menos influenciado por el tiempo de ciclo o las distancias recorridas. Aquí, el tiempo que toma un equipo para regresar a la zona de carga tiene un impacto en el ciclo total, al reducir la distancia mejoraríamos la eficiencia.

Mediante los métodos de Isolation Forest y DBSCAN se detectaron un total de 14,673 valores atípicos. Sin embargo, no fueron eliminados debido a la cantidad de datos y falta información para determinar si es un problema operacional del equipo u otro. Los registros con tonelaje igual a 0 se determinó por eliminarlos. Estos valores corresponden a los camiones CAEX60 y CAEX23, que mostraron problemas en el tonelaje registrado, y palas como PH48, con ciclos excesivamente largos en fechas específicas.

Los equipos presentan tiempos de ciclo relativamente consistentes entre los camiones y palas, con medianas similares, pero algunos camiones presentan mayor dispersión y cantidad de valores atípicos, lo que podría indicar condiciones operativas o mantenimientos diferenciales.

Los camiones que requieren más de 6 paladas tienden a mostrar menor tonelaje promedio y mayor variabilidad, lo que puede señalar ineficiencias en el proceso de carga en estos casos. También, se identificó una tendencia general de aumento en la cantidad de registros diarios, aunque con variaciones notables en días específicos. Las caídas en los registros diarios podrían estar asociadas a eventos operativos, como interrupciones por mantenimiento o condiciones externas.

Por otro lado, del ranking de desempeño permitió identificar de manera integral los equipos con mejor rendimiento, considerando métricas clave como eficiencia de carga, utilización de capacidad, productividad de transporte y eficiencia operativa de las palas. Los equipos mejor posicionados demostraron un uso óptimo de su capacidad máxima, tiempos de ciclo eficientes y una alta productividad en términos de toneladas movidas por distancia, siendo eficiente desde el punto de vista operativo. Por otro lado, al seleccionar otras variables objetivo varía considerablemente el desempeño de equipo en base al transporte de carga siendo mucho mas eficiente los CAEX34 y CAEX62.

Finalmente, del modelo de machine learning se puede observar que el ciclo total de la pala es la variable que más influye en la eficiencia de los equipos, seguida por el tonelaje y las distancias recorridas. La alta variabilidad observada en las distancias y los ciclos totales de la pala sugiere que las rutas y los tiempos de espera tienen un impacto significativo en la operación. Los camiones operan de forma relativamente homogénea, pero algunos presentan ciclos prolongados que pueden deberse a factores externos o condiciones específicas de la operación. El modelo predictivo sin las variables categóricas “truck” y “loader” mostró una

mejor precisión y capacidad explicativa, sugiriendo que estas variables podrían introducir ruido en el modelo. La detección de anomalías a través de Isolation Forest y DBSCAN permitió identificar datos atípicos, aunque no se eliminaron todos debido a la falta de información adicional para confirmar su naturaleza, sin embargo, al eliminar los valores atípicos el rendimiento del modelo disminuía considerablemente, siendo considerados estos datos importantes para el modelo.

## 6. Recomendaciones

1. Se recomienda investigar las rutas de transporte y los tiempos de viaje, especialmente las de retorno, para asegurarse de que están optimizadas y reducir los tiempos de ciclo total. También sería útil analizar los registros de distancias superiores a 12,000 metros para determinar si existen desviaciones o condiciones que puedan mejorarse.
2. Además, se sugiere implementar un sistema de monitoreo para los tiempos de ciclo de las palas y camiones, especialmente para aquellos que presentan ciclos largos, permitiendo así una intervención rápida de casos en donde se pueda extender el uso de la máquina, por mantención o interrupción de la operación.
3. Así mismo, se sugiere estudiar más a fondo los factores externos que influyen en el tonelaje para maximizar la eficiencia del transporte. Además, se recomienda establecer un umbral de paladas óptimo (de 3 a 6 paladas) para mantener la eficiencia de carga, monitoreando cualquier desviación para corregir posibles ineficiencias en el proceso de carga.
4. Se propone analizar más a fondo los días con registros extremos para identificar patrones o factores que puedan afectar a la operación diaria. Además de, analizar a fondo los días con registros altos y bajos para poder identificar los factores operativos que influyen en los resultados.
5. También, se sugiere analizar los registros del ciclo total de la pala, que se encuentren en los rangos superiores a los 10,000 segundos para identificar las causas, y con ello, considerar posibles estrategias operativas para reducir los ciclos largos, favoreciendo a la eficiencia en la operación de carga.

Finalmente, implementar estas recomendaciones contribuirá a mejorar la eficiencia en las operaciones de carga y transporte, pudiendo maximizar el rendimiento de los equipos.